

FACULDADE DE TECNOLOGIA DE JUNDIAÍ - FATEC JUNDIAÍ
CURSO DE TECNOLOGIA EM CIÊNCIA DE DADOS

RODOLFO VINICIUS CIMA TAKEMOTO
TIAGO GALHARDO AVELAR

DATA WAREHOUSE PARA ANÁLISE DA MATRIZ ENERGÉTICA MUNDIAL:
Um estudo sobre geração elétrica renovável, fóssil e de baixo carbono

JUNDIAÍ
2026

RODOLFO VINICIUS CIMA TAKEMOTO

TIAGO GALHARDO AVELAR

DATA WAREHOUSE PARA ANÁLISE DA MATRIZ ENERGÉTICA MUNDIAL:

Um estudo sobre geração elétrica renovável, fóssil e de baixo carbono

Relatório técnico e acadêmico apresentado ao Curso de Tecnologia em Ciência de Dados da Faculdade de Tecnologia de Jundiaí (FATEC Jundiaí), como requisito parcial para a aprovação na disciplina Banco e Armazém de Dados. **Orientação:** Prof. Rafael Gross

JUNDIAÍ

2026

RESUMO

Este relatório apresenta o desenvolvimento de um Data Warehouse (DW) completo, projetado em DuckDB, SQL e Python, destinado a analisar a evolução da geração elétrica mundial por fonte de energia. O principal objetivo é classificar e comparar a geração elétrica de fontes renováveis, fósseis e de baixo carbono entre países e ao longo do tempo, utilizando o dataset público *Our World in Data Energy Dataset*. O modelo dimensional adota a modelagem estrela (Star Schema) de Kimball, contendo uma tabela fato centralizada no grão de país, ano e fonte de energia, e três dimensões de suporte: data, país (com histórico implementado via Slowly Changing Dimension - SCD Tipo 2 por faixas socioeconômicas) e fonte de energia. Para otimizar as consultas analíticas, foi projetada uma tabela agregada anual. As análises englobam a evolução temporal da matriz elétrica brasileira, o ranking dos principais países geradores de fontes renováveis, a agregação multidimensional, a análise de cohort para a penetração de energia solar e o cálculo de KPIs de negócio. O pipeline implementado é totalmente idempotente, garantindo reprodutibilidade das cargas. Os testes de validação de integridade referencial demonstraram ausência de chaves órfãs e total consistência lógica dos dados consolidados no banco de dados colunar DuckDB.

Palavras-chave: Data Warehouse. Modelagem Dimensional. DuckDB. Transição Energética. SCD Tipo 2.

ABSTRACT

This report presents the development of a complete Data Warehouse (DW), designed with DuckDB, SQL and Python, to analyze the evolution of global electricity generation by energy source. The main objective is to classify and compare electricity generation from renewable, fossil and low-carbon sources across countries and over time, using the public *Our World in Data Energy Dataset*. The dimensional model follows Kimball's Star Schema approach, with a fact table defined at the grain of country, year and energy source, supported by three dimensions: date, country and energy source. The country dimension implements Slowly Changing Dimension Type 2 (SCD Type 2) to preserve historical changes in population and GDP per capita bands. The project also includes analytical queries, quality validations, visualizations, a dashboard and a performance comparison based on an aggregated annual table.

Keywords: Data Warehouse. Dimensional Modeling. DuckDB. Energy Transition. SCD Type 2.

SUMÁRIO ESTRUTURADO

- * Resumo
- * Abstract
- * 1 Introdução
- * 2 Fundamentação Teórica
- * 3 Metodologia e Fonte de Dados
- * 4 Modelagem Dimensional do Data Warehouse
- * 5 Pipeline de Carga (ETL) e Idempotência
- * 6 Consultas Analíticas e KPIs de Negócio
- * 7 Visualizações Gráficas e Dashboard
- * 8 Avaliação de Performance e Otimização
- * 9 Resultados e Validação de Qualidade de Dados
- * 10 Conclusão
- * Referências

1 INTRODUÇÃO

A transição para matrizes de geração elétrica com menor intensidade de emissão de carbono constitui um dos principais desafios contemporâneos na agenda geopolítica e ambiental global. O acompanhamento rigoroso do progresso das energias renováveis e de baixo carbono, em comparação com os combustíveis fósseis tradicionais, demanda a consolidação de grandes volumes de dados históricos. Contudo, bases de dados brutas de caráter público costumam apresentar estruturas transacionais (wide tables) com dezenas de colunas esparsas e problemas de integridade referencial, o que inviabiliza análises analíticas ágeis e de alta granularidade.

Neste contexto, o presente projeto acadêmico propõe a modelagem e a construção de um Data Warehouse (DW) robusto focado na análise da Matriz Energética Mundial. O objetivo geral é estabelecer um pipeline analítico ponta a ponta que processe os dados reais da *Our World in Data (OWID)*, estruture-os em um esquema dimensional estrela e produza análises fundamentadas sobre a evolução temporal, o ranking de liderança em energias limpas e o comportamento de cohorts de países na transição para fontes específicas, como a energia solar. O relatório a seguir é estruturado em padrão acadêmico inspirado nas normas ABNT, especialmente NBR 14724 e NBR 6023, documentando rigorosamente a arquitetura conceitual e física adotada.

2 FUNDAMENTAÇÃO TEÓRICA

2.1 Modelagem Dimensional de Kimball

A arquitetura dimensional consolidada por Ralph Kimball preconiza que o banco de dados analítico deve ser estruturado com foco na facilidade de uso pelos tomadores de decisão e no alto desempenho de leitura. O modelo estrela (*Star Schema*) organiza a base em dois tipos de tabelas: as tabelas fato, que armazenam as medidas quantitativas e numéricas dos eventos de negócio (métricas), e as tabelas dimensão, que descrevem o contexto detalhado do evento (quem, onde, quando, o quê). Essa separação reduz o número de junções necessárias na execução das consultas SQL comparado ao modelo normalizado tradicional (Entity-Relationship).

2.2 Camadas de Dados: Staging e OLTP Intermediário

A construção de um armazém de dados moderno adota uma estratégia de separação de responsabilidades em camadas físicas de dados:

- **Camada Staging (stg):** Área de pouso dos dados extraídos na qual o arquivo bruto (CSV) é ingerido sem transformações estruturais de negócio. O foco principal é a carga rápida e a conversão inicial dos tipos primitivos de dados.
- **Camada OLTP Intermediária (oltp):** Área de preparação na qual os dados sofrem normalização, filtragem de registros inválidos (como códigos ISO não nacionais) e enriquecimento conceitual preliminar (determinação de faixas populacionais e cálculo do PIB per capita).

2.3 Histórico de Dimensões com SCD Tipo 2

A técnica de dimensões que sofrem alteração lenta (*Slowly Changing Dimensions* - SCD) resolve o desafio de rastrear dados descritivos que mudam ao longo do tempo. Na SCD Tipo 2, quando um atributo descritivo de uma dimensão sofre modificação, uma nova linha é inserida na tabela contendo a nova versão do registro, atribuindo-se chaves substitutas distintas para cada estado histórico e controlando sua vigência com atributos de tempo (`start_year`, `end_year` e o marcador lógico `is_current`). No escopo deste projeto, a dimensão de país cria versões históricas para preservar a exatidão analítica no momento do registro do fato quando faixas de população ou PIB per capita mudam de intervalo de classificação.

2.4 Banco de Dados Analítico DuckDB

O DuckDB é um sistema de gerenciamento de banco de dados (SGBD) relacional voltado para processos analíticos (OLAP) de vetorização colunar em memória. Projetado para integração profunda com ambientes de programação Python e R, ele oferece execução SQL nativa veloz sobre dados tabulares estruturados, combinando a facilidade de implantação de um banco embarcado (como o SQLite) com o poder analítico de processamento de consultas com agregação rápida típicos de grandes plataformas corporativas.

3 METODOLOGIA E FONTE DE DADOS

O pipeline utiliza o dataset unificado **Our World in Data Energy Dataset**, mantido publicamente e atualizado continuamente pela OWID. A extração dos dados brutos é feita via requisição HTTP direta ao arquivo CSV hospedado na infraestrutura pública da OWID:

```
https://owid-public.owid.io/data/energy/owid-energy-data  
.csv
```


A metodologia de desenvolvimento compreende as seguintes fases:

1. **Ingestão automatizada:** Download condicional e dinâmico do CSV em lote.
2. **Transformação Estrutural (Pipeline SQL):** Execução ordenada de 6 scripts SQL em lote no DuckDB. O fluxo limpa dados, normaliza tabelas e preenche as chaves substitutas no banco.
3. **Carga e Medição:** População física da tabela fato e das tabelas dimensões no banco colunar, gerando dados analíticos limpos de forma idempotente.
4. **Visualização e Publicação:** Geração automatizada de gráficos em vetor SVG e consolidação de um Dashboard HTML estático acoplado a relatórios em PDF.

4 MODELAGEM DIMENSIONAL DO DATA WAREHOUSE

O modelo analítico do projeto adota a arquitetura estrela clássica com relacionamentos de integridade referencial implementados através de chaves substitutas (*surrogate keys*).

Figura 1 - Diagrama visual do modelo estrela



4.1 Grão da Tabela Fato

O grão da tabela fato `dw.fact_energy_generation` é definido como: **uma linha por país, ano e fonte de energia**. Isso assegura granularidade suficiente para detalhar a transição da matriz energética em nível nacional sem inflar desnecessariamente o volume de armazenamento analítico.

4.2 Atributos das Dimensões

- `dw.dim_date`: Armazena o ano como a chave de tempo primária. Os atributos associados são a década correspondente, o primeiro dia do ano de referência (`year_start_date`), o flag de ano atual do sistema (`is_current_year`) e o flag indicativo do ano mais recente presente na base histórica do dataset (`is_latest_dataset_year`).
- `dw.dim_country`: Dimensão histórica (SCD Tipo 2). Contém a chave substituta autogerada (`country_key`), o nome do país, o código ISO-3 de identificação internacional, faixas descritivas de classificação populacional (`population_band`) e de PIB per capita (`gdp_per_capita_band`), além dos intervalos de vigência temporal do registro (`start_year` e `end_year`) e do sinalizador de registro atual (`is_current`).
- `dw.dim_energy_source`: Classifica as fontes energéticas. Armazena o nome da fonte (Solar, Wind, Hydro, Nuclear, Coal, Gas, Oil, Biofuel, Other renewable), o grupo conceitual correspondente (Renewable, Fossil, ou Low Carbon) e os respectivos sinalizadores lógicos (`is_renewable` e `is_low_carbon`).

4.3 Definição das Métricas

A tabela fato armazena as seguintes variáveis quantitativas:

- `electricity_twh`: Volume físico bruto de geração elétrica no ano medido em Terawatt-hora.
- `electricity_share_pct`: Participação percentual que a fonte específica representa sobre o total de geração de eletricidade da localidade naquele ano.
- `population` e `gdp`: Métricas demográficas e econômicas de contexto para a ponderação ponderada de indicadores socioeconômicos.

5 PIPELINE DE CARGA (ETL) E IDEMPOTÊNCIA

O pipeline ETL foi projetado para rodar em lote e ser rigorosamente idempotente. Isso significa que, independentemente de quantas vezes o pipeline de carga for reexecutado, o estado final do Data Warehouse permanecerá consistente e sem duplicação física de registros nas tabelas dimensionais ou fatos.

O fluxo é sequenciado pelos scripts localizados no diretório `/scripts`:

1. `00_staging.sql`: Cria o esquema de staging e importa o CSV.
2. `01_oltp.sql`: Normaliza e transpõe a tabela larga da OWID em tabelas longas relacionais, estruturando as observações de fonte em linhas.
3. `02_dw_model.sql`: Cria fisicamente a estrutura relacional do DW com chaves primárias e relacionamentos.
4. `03_etl_load.sql`: Executa a lógica de Slowly Changing Dimension (SCD Tipo 2) para a tabela de países e popula a tabela fato por meio de cruzamentos históricos usando `o.year BETWEEN c.start_year AND c.end_year`.
5. `04_analytics.sql`: Consolida os resultados das consultas analíticas e gera as tabelas de validação.
6. `05_performance.sql`: Agrupa dados em tabelas físicas para aceleração de relatórios.

6 CONSULTAS ANALÍTICAS E KPIS DE NEGÓCIO

Foram consolidadas cinco consultas analíticas obrigatórias materializadas no banco de dados analítico DuckDB:

- **Q1 - Evolução Temporal:** Mede o crescimento e a variação da geração elétrica das fontes eólica, solar e hidrelétrica no Brasil ano a ano, mapeando a evolução física da geração limpa nacional.
- **Q2 - Ranking TOP N:** Lista os 10 principais países geradores de energia renovável (em TWh) no ano mais recente do dataset (2025).
- **Q3 - Agregação Multidimensional:** Agrupa a geração elétrica em TWh consolidando por grupo de fonte (Renováveis, Fósseis e Baixo Carbono) e por país para fins de comparação geopolítica.
- **Q4 - Análise de Cohort e Retenção:** Identifica a data em que cada país rompeu o patamar de 1% de participação de energia solar na sua matriz e calcula a taxa de permanência acima dessa linha de corte nos anos subsequentes.
- **Q5 - KPI de Participação Renovável:** Calcula o percentual ponderado de geração limpa em relação ao total modelado de energia de cada país, fornecendo um indicador do progresso rumo à descarbonização.

7 VISUALIZAÇÕES GRÁFICAS E DASHBOARD

A validação analítica gerou quatro visualizações obrigatórias salvas em formatos vetoriais e integradas no painel visual:

- 1. **Gráfico de Linha:** Representa a evolução temporal das energias Solar, Eólica e Hidrelétrica no Brasil, evidenciando o crescimento expressivo das novas renováveis.
- 2. **Gráfico de Barras:** Exibe o ranking dos top 10 maiores produtores de eletricidade limpa em 2025.
- 3. **Heatmap Analítico:** Representa de forma matricial a evolução percentual de cada fonte de geração elétrica na matriz do Brasil ao longo dos anos.
- 4. **Dashboard HTML Integrado:** Uma interface estática web unificada que centraliza KPIs de negócio essenciais e renderiza nativamente os gráficos SVG associados e tabelas de benchmark.

Figura 2 - Evolução da geração solar, eólica e hidrelétrica no Brasil




Figura 3 - Top 10 países por geração renovável no ano mais recente





Figura 4 - Heatmap da participação das fontes na eletricidade brasileira



8 AVALIAÇÃO DE PERFORMANCE E OTIMIZAÇÃO

Para otimizar o tempo de resposta das consultas corporativas de nível gerencial, foi criada a tabela agregada física `dw.fact_energy_generation_annual_grouped`, que pré-calcula a soma das gerações anuais agregadas por ano, país e grupo conceitual de fonte de energia.

Um teste comparativo de benchmark foi conduzido para medir os tempos médios de resposta do banco ao executar a mesma agregação a partir da tabela fato original com múltiplos joins dimensionais versus a leitura otimizada na tabela agregada.

Os dados obtidos empiricamente com o dataset real apontam:

- **Consulta Fato Original:** Média de **8,79 ms** por consulta.
- **Consulta Tabela Agregada:** Média de **2,68 ms** por consulta.

Isso representa um ganho médio de velocidade de **3,27 vezes** na renderização e recuperação de relatórios analíticos anuais agrupados.

9 RESULTADOS E VALIDAÇÃO DE QUALIDADE DE DADOS

Para manter o rigor e a confiabilidade analítica exigida, foram estruturadas quatro consultas de teste e qualidade de dados materializadas em tabelas de auditoria:

1. `validation_row_counts`: Realiza o censo físico de linhas por tabela para auditoria de perdas no ETL.

2. `validation_fk_nulls`: Verifica a integridade física de chaves estrangeiras nulas na tabela fato. O teste acusou 0 ocorrências de chaves nulas em todas as dimensões de junção.

3. `validation_integrity`: Detecta chaves órfãs na fato com buscas lógicas (left joins). O teste acusou zero órfãos nas conexões dimensionais.

4. `validation_generation_by_source`: Verifica se as somas brutas das fontes fecham com as quantidades consolidadas na extração primária.

10 CONCLUSÃO

O presente projeto demonstrou a viabilidade prática da construção de um Data Warehouse de alto desempenho focado em transição energética e sustentabilidade. Através da modelagem estrela de Kimball e da implementação física sobre o SGBD DuckDB, foi possível extrair dados brutos e não estruturados da Our World in Data, limpá-los por meio de staging, transpor métricas via camadas intermediárias e carregá-los de forma consistente, preservando o histórico geográfico via SCD Tipo 2.

Os testes de qualidade e consistência física evidenciaram um DW confiável, seguro para reexecuções e ágil, com ganhos expressivos de performance através do uso de tabelas agregadas. A estruturação acadêmica do relatório técnico com foco nas principais teorias e nas normas indicativas contribui para a clareza expositiva do artefato de engenharia de dados entregue.

REFERÊNCIAS

DUCKDB. **DuckDB Documentation**. Disponível em: <<https://duckdb.org/docs/>>. Acesso em: 25 mai. 2026.

KIMBALL, Ralph; ROSS, Margy. **The Data Warehouse Toolkit**: The Definitive Guide to Dimensional Modeling. 3. ed. Indianapolis: John Wiley & Sons, 2013.

OUR WORLD IN DATA. **OWID Energy Dataset**. Disponível em: <<https://owid-public.owid.io/data/energy/owid-energy-data.csv>>. Acesso em: 25 mai. 2026.

PANDAS. **Pandas: powerful Python data analysis toolkit**. Disponível em: <<https://pandas.pydata.org/docs/>>. Acesso em: 25 mai. 2026.

PYTHON SOFTWARE FOUNDATION. **Python Language Reference**, version 3.12. Disponível em: <<https://www.python.org/>>. Acesso em: 25 mai. 2026.